学习到的知识

提示词工程

术语	内容
zero-shot learning	**零样本学习**，指的是在训练阶段不存在与测试阶段完全相同的类别， 但是模型可以使用训练过的知识推理到测试集中的新类别上 在提示词优化中，不提供示例，仅仅通过语言描述任务要求、目标和约束，让模型直接生成结果。用语言定义任务，解放模型的预训练知识
Few-shot Learning	**少样本学习**，指的是模型学习了某种类别的大量数据后，对于新的类别，只需要少量的样本就能快速学习， 对应也有one-shot learning，单样本学习 在提示词优化中，主要用于基于少量示例，让模型参考回答

LangChain

（一）介绍

是Python的第三方库，提供了各种功能的API

相当于编程中的SDK，为各种LLMs实现通用的接口，把LLMs相关组件连接在一起，简化LLM应用的开发难度，快速实现复杂LLMs应用

是后续学习RAG开发的主力框架

主要功能	内容
Prompts	优化提示词（提示词工程）
Models	调用各种模型
History	管理会话历史记录
Indexes	管理和分析各类文档
Chains	构建功能的执行链条
Agent	构建智能体

目前LangChain支持的三种类型的模型：LLMs，Chat Models，Embedding Models

模型	内容
LLMs	基于大量参数，海量文本训练的Transformer架构模型，核心：理解和生成自然语言
聊天模型	专为对话场景优化
文本嵌入模型	接受文本作为输入，得到文本的向量

（二）环境部署

pip install langchain langchain-community langchain-ollama dashscope chromadb

langchain：核心包
langchain-commun：社区支持包
langchain-ollama：调用部署到本地的模型
dashscope：阿里云通义千问的Python SDK
chromadb:轻量向量数据库

RAG

（一）介绍

Retrieval Augmented Generation 检索增强生成技术，利用检索外部文档提升生成结果的质量。可以总结成一个公式：

RAG = 检索技术 + LLM提示

标准流程三个阶段：**索引、检索、生成**

阶段	工作内容
索引 Indexing	处理多种来源各种格式的文档提取其中的文本，将其切分为标准长度文本块（chunk），并进行嵌入向量化（embedding），向量存储在向量数据库（vector database）中
检索 Retriever	用户输入的查询（query）被转化为向量表示，通过相似度匹配从向量数据库中检索出最相关的文本块
生成 Generation	检索到的文本和原始查询共同构成一个提示词（prompt），输入LLM，生成回答

（二）存在意义

通用大模型存在的问题：

- LLM只是不是实时的，模型训练好后不具备自动更新知识的能力（信息滞后）
- LLM缺乏领域知识，数据主要来自公开的互联网和开源数据集，无法覆盖特定领域或者高度专业化的内部知识
- AI幻觉
- 数据安全性

（三）核心价值

- 解决知识时效性
- 降低模型幻觉
- 无需重新训练

向量

（一）介绍

将文字语义信息转换成固定长度的数字列表，方便计算机做相似度计算

文本嵌入模型通过深度学习技术转换向量

后面通过余弦相似度等算法计算，从而提高语义匹配的效率与精度

生成向量的维度是一个很重要的指标，维度越多更容易精准，但是生成、存储和匹配过程中压力更大

（二）余弦相似度

余弦相似度撇出长度影响，得到方向夹角，夹角越小越相似，方向越近

其实就是高中的两个向量余弦计算公式

Chat Models 聊天模型

（一）分类

类型	作用
AIMessage	AI输出的消息，可以是针对问题的回答
HumanMessage	人类消息，即用户的消息
SystemMessage	用于指定模型具体所处的环境和背景

LangChain消息简写

调用聊天模型的时候有静态和动态两种，动态使用tuples。

使用动态有个好处：可以在调用时注入变量，可以在运行的时候填充具体的值。如果使用上述Message静态，会导致不能注入变量，使用场景会受到更大的限制。

Embedding Models文本嵌入模型

介绍

将字符串作为输入，返回一个浮点数的列表（向量）。在NLP中，作用就是将数据进行文本向量化。

拓：NLP 的全称是 Natural Language Processing，自然语言处理，是人工智能（AI）的一个核心分支，研究的是让计算机理解、处理、生成人类自然语言的技术。

目前所掌握的LangChain API如下

方式	LLMs大语言模型	聊天模型	文本嵌入模型
阿里云千问	from langchain_community.llms.tongyi import Tongyi	from langchain_community.chat_models.tongyi import ChatTongyi	from langchain_community.embeddings import DashScopeEmbeddings
Ollama本地模型	from langchain_ollama import OllamaLLM	from langchain_ollama import ChatOllama	from langchain_ollama import OllamaEmbeddings
方法	invoke批量/stream流式	invoke批量/stream流式	embed_query 单次转换 embed_documents 批量转换

Prompt Template 提示词模板

（一）PromptTemplate 通用提示词模板（ZeroShot提示词模板）

提示词优化在模型应用非常重要，LangChain提供了PromptTemplate类协助优化提示词。

PromptTemplate表示提示词模板，可以构建一个自定义的基础提示词模板，支持变量注入，最终生成所需要的提示词。

（二）FewShotPromptTemplate FewShot提示词模板

FewShotTemplate有五个参数

参数	作用
examples	示例数据，list，字典
example_prompt	示例数据的提示词模板
prefix	组装提示词，示例数据前面的内容
suffix	组装提示词，示例数据后的内容
input_variables	列表，注入的变量列表

（三）ChatPromptTemplate

模板	内容
PT	通用提示词模板，支持动态注入信息
FSPT	支持基于模板注入任意数量的示例信息
CPT	支持注入任意数量的历史会话信息

通过from_message方法，从列表中获取多轮次会话作为聊天的基础模板
前面的PromptTemplate类用的from_template仅能接入一条信息，而from_message可以接入一个list的消息

历史会话信息不是静态的，是随着对话不停地积攒，是动态的。所以，**历史会话信息需要支持动态注入。**

MessagePlaceHolder作为占位，提供history作为占位的key，基于invoke动态注入历史会话记录，**必须要求invoke**

（四）提示词模板关系

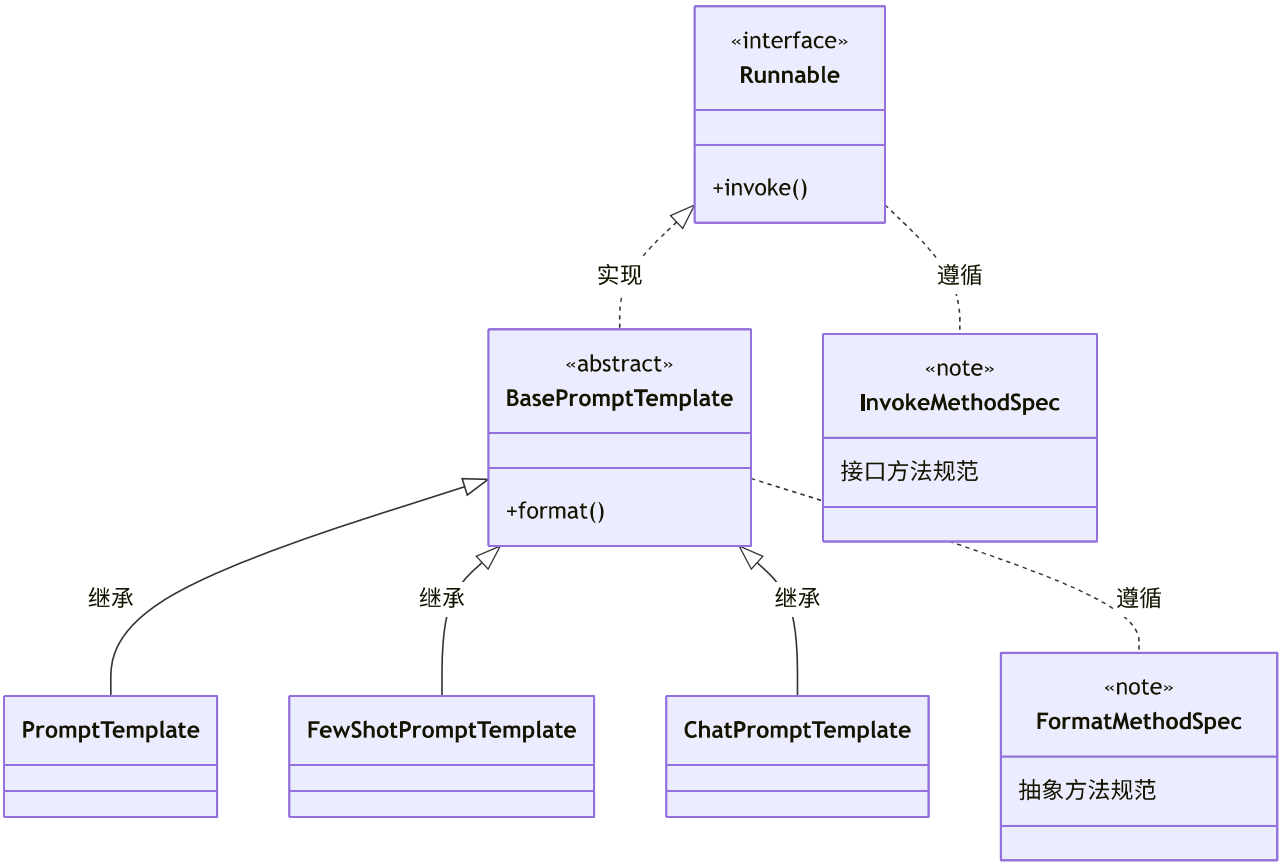

（五）模板类的format和invoke方法

区别	format	invoke
功能	纯字符串替换，解析占位符生成提示词	Runnable接口标准方法，解析占位符生成提示词
返回值	字符串	PromptValue类对象
传参	.format(k=v, k=v, ...)	.invoke({"k":v, "k":v, ...})
解析	支持解析{}占位符	支持解析{}占位符和MessagesPalceholder结构化占位符

invoke的使用更加广泛

chain链

将组件传脸，上一个组件的输出作为下一个组件的输入，是LangChain链的核心工作原理，这也是链式调用的核心价值：实现数据的自动化流转和组件协同工作。

核心前提：Runnable子类对象才能入链（以及Callable、Mapping接口子对象也可以）

Runnable接口

LangChain大多数核心组件都继承了Runnable抽象基类。

StrOutputParser 字符串输出解析器

介绍

是LangChain内置的简单字符串解析器。

可以将AIMessage解析为简单的字符串，符合模型invoke方法的要求（可以传入字符串，不接受AIMessage类型）；也是Runnable接口的子类（可以加入链）。

JsonOutputParser完成多模型链

原：chain = prompt | model | parser | model | parser
前面构建多模型链并不标准：上一个模型的输出，没有被处理就输入了下一个模型
根据要求：
invoke | stream 初始输入 -> 提示词模板 -> 模型 -> **数据处理** -> **提示词模板** -> 模型 -> 解析器 -> 结果
即：AImsg -> 字典 -> 注入第二个提示词模板中

RunnableLambda

介绍

是LangChain内置的，将普通函数转换为Runnable接口实例，方便自定义函数加入chain

语法为：RunnableLambda(函数对象 或者 lambda匿名函数)